



Université du Québec à Rimouski

Département de mathématiques, d'informatique et de génie

8INF976 - Sujet spécial en intelligence artificielle

Efficacité et compression

Rapport de lecture

Réalisé par : Pier-Luc Dupéré

Professeur : Mehdi Adda, PhD

Table des matières

1	Quantification	1
2	Élagage (pruning)	3
3	Distillation	5
4	LoRA/QLoRA	6

Table des figures

1.1	Une technique de quantification qui consiste à réduire intentionnellement la précision des représentations numériques.	1
2.1	Élagage de SparseGPT en une seule étape.	3
4.1	LoRA réduit fortement le nombre de paramètres à optimiser et la mémoire consacrée aux gradients.	6
4.2	Le modèle QLoRA avec une précision de 4 bits qui effectue la pagination en mémoire GPU.	7

Chapitre 1

Quantification

La quantification est un processus qui consiste à représenter des données numériques avec une précision réduite afin d'en diminuer la taille ou d'en simplifier le traitement. Cette réduction de la précision permet de limiter les besoins en stockage, en bande passante ou en puissance de calcul, au prix d'une perte d'information généralement acceptable. Cela permet donc, l'optimisation des ressources et une meilleur accessibilité.




FIGURE 1.1 – Une technique de quantification qui consiste à réduire intentionnellement la précision des représentations numériques.

Il existe différentes stratégies existant pour quantifier les grands modèles de langage :

- **Quantification post-entraînement (PTQ)** : fait référence à l'ajustement des poids du modèle une fois l'entraînement terminé.

- **Formation de la quantification (QAT) :** intègre le processus de quantification pendant la formation du modèle. De plus, les modèles peuvent apprendre à s'adapter aux contraintes de précision dès le départ.

La quantification peut entraîner des pertes lorsque les LLM sont des modèles généralistes. La quantification (QAT) peut manquer d'efficacité en raison de son coût d'entraînement élevé. La quantification post-entraînement (PTQ) entraîne une dégradation importante de la précision en faible précision.

AWQ (Activation Aware Weight Quantization) est une méthode de quantification qui atteint une excellente compression avec une perte de qualité minimale. L'idée derrière AWQ est que tous les poids d'un modèle ne sont pas également importants. AWQ identifie les poids les plus importants en examinant les motifs d'activation. La quantification traditionnelle traite tous les poids de la même manière. AWQ applique plus de précision aux poids ayant le plus grand impact sur la sortie. Le processus fonctionne en analysant un petit ensemble de données de calibration. AWQ mesure quels poids ont la plus forte influence sur les résultats.

Chapitre 2

Élagage (pruning)

L'élagage est le processus consistant à éliminer les poids, neurones ou couches inutiles d'un réseau de neurones afin d'obtenir un modèle plus compact, plus rapide et plus efficace.

L'identification des redondances : La suppression de composants : Le réglage fin (fine-tuning) :

- **L'identification des redondances** : repérer les paramètres qui contribuent peu aux résultats du modèle.
- **La suppression de composants** : supprimer ces paramètres sans nuire de manière significative à la précision.
- **Le réglage des paramètres** : ré-entraîner le modèle élagué pour restaurer les performances perdues.

SparseGPT procède en ramenant le problème de l'élagage (ne seule étape) à un ensemble d'instances de régression creuse à très grande échelle. Il résout ensuite ces instances grâce à un nouvel algorithme de résolution approchée pour la régression creuse, suffisamment efficace pour s'exécuter en quelques heures sur les plus grands modèles GPT accessibles au public (175 milliards de paramètres) à l'aide d'un seul GPU




FIGURE 2.1 – Élagage de SparseGPT en une seule étape.

La compression après entraînement s'effectue généralement en décomposant le problème de compression du modèle complet en sous-problèmes propres à chaque couche. Il existe plusieurs façons de faire de l'optimisation via de l'élagage :

- **Élagage non structuré** : Supprimer les poids ayant les plus faibles valeurs absolues
- **Élagage structuré** : Suppression de canaux, neurones, têtes d'attention ou blocs entiers
- **Élagage itératif ou dynamique** : Élaguer graduellement le modèle pendant l'entraînement, lui permettant de s'adapter en fonction de l'ampleur de la variation des poids.
- **Élagage global ou local** : Supprimer les plus petits poids sur l'ensemble du modèle global. Enlève des poids au sein de couches individuelles.

Chapitre 3

Distillation

Distillation : knowledge distillation classique, distillation de LLM vers petit LLM (TinyLlama, Phi, distil-whisper, etc.)

La distillation transfère les connaissances d'un modèle enseignant vers un modèle étudiant. L'étudiant apprend à reproduire les sorties de l'enseignant, éventuellement à partir d'une combinaison de perte supervisée et de perte de distillation. La distillation permet de réduire directement la taille de l'architecture. Elle peut donc produire des gains importants en mémoire et en latence. Toutefois, elle nécessite :

un modèle enseignant performant ; un corpus représentatif ; une phase d'entraînement supplémentaire ; un réglage de la température et des pondérations de pertes.

Elle est particulièrement intéressante lorsque la latence cible est stricte ou lorsqu'un modèle beaucoup plus petit est nécessaire. Elle est moins adaptée si l'objectif prioritaire est de conserver le comportement général d'un grand modèle avec un budget expérimental limité.

Chapitre 4

LoRA/QLoRA

LoRA (Low-rank Adapters) : Le réglage fin par adaptateurs de rang faible (LoRA) est une méthode qui réduit les besoins en mémoire en utilisant un petit ensemble de paramètres entraînables sans mettre à jour l'intégralité des paramètres du modèle. LoRA décompose la mise à jour en deux matrices de rang réduit, ce qui augmente l'efficacité de LoRA en termes de mémoire et de vitesse.




FIGURE 4.1 – LoRA réduit fortement le nombre de paramètres à optimiser et la mémoire consacrée aux gradients.

QLoRA est une méthode de réglage fin efficace en paramètres qui combine un modèle pré-entraîné figé et quantifié en 4 bits avec des adaptateurs LoRA de bas rang.

QLoRA permet notamment d'ajuster des modèles très volumineux, jusqu'à 65 milliards de paramètres, sur un seul GPU de 48 Go, tout en conservant des performances proches d'un réglage fin complet en précision 16 bits. Le banc d'essai Vicuna, atteignant 99,3 % des performances de ChatGPT tout en ne nécessitant que 24 heures d'ajustement fin sur un seul GPU.

- **Le format 4-bit NormalFloat NF4** : un nouveau type de données optimal au sens de la théorie de l'information pour des poids suivant une distribution

normale. Cette méthode repose sur la quantification par quantiles, une méthode optimale du point de vue de la théorie de l'information qui garantit que chaque intervalle de quantification reçoit un nombre égal de valeurs issues du tenseur d'entrée.

- **Double quantification** : la double quantification, pour réduire l'empreinte mémoire moyenne en quantifiant les constantes de quantification. La première étape consiste à traiter des entrées pour une seconde quantification. Cette étape produit des constantes de quantification quantifiées. La seconde étape, on utilise des nombres à virgule flottante sur 8 bits avec une taille de bloc de 256, car aucune dégradation des performances n'est observée avec une quantification sur 8 bits.
- **Optimiseurs paginés** : pour gérer les pics de consommation mémoire et éviter tout dépassement. On exploite la fonctionnalité « Unified Memory 3 » de NVIDIA, qui assure des transferts automatiques de pages entre le CPU et le GPU. Cela permet un traitement GPU sans erreur même lorsque la mémoire du GPU vient à manquer ponctuellement.

QLORA utilise un type de données de stockage à faible précision (généralement 4 bits) et un type de données de calcul (généralement BFloat16). En pratique, cela signifie que chaque fois qu'un tenseur de poids QLORA est utilisé, nous déquantifions le tenseur en BFloat16, puis nous effectuons une multiplication matricielle en 16 bits.




FIGURE 4.2 – Le modèle QLoRA avec une précision de 4 bits qui effectue la pagination en mémoire GPU.

Bibliographie

- [1] Lin, J., Tang, J., Tang, H., Yang, S., Dang, X., Gan, C. et Han, S., *AWQ : activation-aware weight quantization for on-device llm compression and acceleration*, <https://arxiv.org/pdf/2306.00978v6>, consulté le 30 septembre 2026.
- [2] Frantar, E. et Alistarh, D., *SparseGPT : Massive Language Models Can be Accurately Pruned in One-Shot*, <https://arxiv.org/pdf/2301.00774v3>, consulté le 30 septembre 2026.
- [3] Hinton, G., Vinyals, O. et Dean, J., *Distilling the Knowledge in a Neural Network*, <https://arxiv.org/pdf/1503.02531v1>, consulté le 30 septembre 2026.
- [4] Dettmers, T., Pagnoni, A., Holtzman, A. et Zettlemoyer, L., *QLORA : Efficient Finetuning of Quantized LLMs*, <https://arxiv.org/pdf/2305.14314v1>, consulté le 30 septembre 2026.